

Análise Exploratória de Falhas

Israel

2025-02-12

1. Carregamento e Preparação dos Dados

Carregamento dos dados

Visualização das primeiras linhas

```
head(dados)

## # A tibble: 6 × 12
##   ID          DATA DETECCAO` PONTO LOC_ID LOC   POS_ID POS   TYPE_ID TYPE_TEXT
##   <chr>         <chr>         <chr> <dbl> <chr> <dbl> <chr> <dbl> <chr>
## 1 2024-3712154 2010-01-29-02.... RODA... 5.56e3 Tamp... -2 <NA> 70 "070 - R...
## 2 2024-3722068 2010-01-29-02.... RODA... 5.56e3 Tamp... -2 <NA> 70 "070 - R...
## 3 2024-3732080 2010-01-29-02.... RODA... 7.06e3 Reve... 5 dire... 70 "070 - R...
## 4 2024-3732079 2010-01-29-02.... RODA... 5.85e3 Port... 5 dire... 70 "070 - R...
## 5 2024-3731076 2010-01-29-02.... RODA... 4.66e3 Alav... -2 <NA> 5 "005 - B...
## 6 2024-3732094 2010-01-29-04.... RODA... 9.88e7 Regu... 3 esqu... 31 "031 - P...
## #   3 more variables: VIEW_ID <dbl>, COLUNA <chr>, LINHA <dbl>
```

Verificação da estrutura dos dados

```
str(dados)

## spec_tbl_ [679,073 × 12] (S3: spec_tbl_df/tbl_df/tbl/data.frame)
## $ ID          : chr [1:679073] "2024-3712154" "2024-3722068" "2024-3732079" ...
## $ DATA DETECCAO: chr [1:679073] "2010-01-29-02.25.25.000000" "2010-01-29-02.38.57.000000" "2010-01-29-02.44.5
4.000000" "2010-01-29-02.53.28.000000" ...
## $ PONTO       : chr [1:679073] "RODAGEM" "RODAGEM" "RODAGEM" "RODAGEM" ...
## $ LOC_ID      : num [1:679073] 5559 5559 7057 5851 4661 ...
## $ LOC         : chr [1:679073] "Tampa traseira" "Tampa traseira" "Revestimento coluna A" "Porta traseira"
...
## $ POS_ID      : num [1:679073] -2 -2 5 5 -2 3 3 5 4 3 ...
## $ POS         : chr [1:679073] NA NA "direita" "direita" ...
## $ TYPE_ID     : num [1:679073] 70 70 70 70 5 31 70 70 70 70 ...
## $ TYPE_TEXT   : chr [1:679073] "070 - Ruído" "070 - Ruído" "070 - Ruído" ...
## $ VIEW_ID     : num [1:679073] NA NA NA NA NA NA NA NA ...
## $ COLUNA      : chr [1:679073] NA NA NA NA ...
## $ LINHA       : num [1:679073] NA NA NA NA NA NA NA NA ...
## - attr(*, "spec")=
##   .. cols(
##   ..   ID = col_character(),
##   ..   DATA DETECCAO` = col_character(),
##   ..   PONTO = col_character(),
##   ..   LOC_ID = col_double(),
##   ..   LOC = col_character(),
##   ..   POS_ID = col_double(),
##   ..   POS = col_character(),
##   ..   TYPE_ID = col_double(),
##   ..   TYPE_TEXT = col_character(),
##   ..   VIEW_ID = col_double(),
##   ..   COLUNA = col_character(),
##   ..   LINHA = col_double()
##   .. )
## - attr(*, "problems")=externalptr>
```

2. Resumo Estatístico e Descrição dos Dados

Resumo estatístico

```
summary(dados)

##           ID          DATA DETECCAO          PONTO          LOC_ID
## Length:679073      Length:679073      Length:679073      Min.   : 1001
## Class :character    Class :character    Class :character    1st Qu.: 5145
## Mode  :character    Mode  :character    Mode  :character    Median : 5559
##                                     Mean  : 3520407
##                                     3rd Qu.: 5851
##                                     Max.   :99008995
##
##           LOC          POS_ID          POS          TYPE_ID
## Length:679073      Min.   : -2      Length:679073      Min.   : 1
## Class :character    1st Qu.: 1      Class :character    1st Qu.: 39
## Mode  :character    Median : 10      Mode  :character    Median : 89
##                                     Mean  : 49464
##                                     3rd Qu.: 17
##                                     Max.   :9799976
##                                     Max.   :99008934
##
##           TYPE_TEXT          VIEW_ID          COLUNA          LINHA
## Length:679073      Min.   :.661.0      Length:679073      Min.   :1.00
## Class :character    1st Qu.:.673.0      Class :character    1st Qu.:2.00
## Mode  :character    Median :.689.0      Mode  :character    Median :3.00
##                                     Mean  :.699.3
##                                     3rd Qu.:.723.0
##                                     Max.   :.778.0
##                                     NA's   :98563
##                                     NA's   :98564
```

Descrição das variáveis


O conjunto de dados contém as seguintes variáveis: - **ID**: Identificador único da falha. - **DATA DETECCAO**: Data e hora em que a falha foi detectada. - **PONTO**: Local do problema. - **LOC_ID**: Identificação numérica da localização. - **LOC**: Descrição da localização. - **POS_ID**: Identificação da posição do problema. - **POS**: Posição textual (ex: esquerda/direita). - **TYPE_ID**: Código do tipo de falha. - **TYPE_TEXT**: Descrição do tipo de falha. - **VIEW_ID**: Identificação do ponto de vista da inspeção. - **COLUNA**: Identificação textual da coluna. - **LINHA**: Identificação numérica da linha.

3. Análise Univariada


Visualização das distribuições

```
ggplot(dados, aes(x = LOC_ID)) +
  geom_histogram(binwidth = 50, fill = "blue", color = "black") +
  labs(title = "Distribuição de LOC_ID", x = "LOC_ID", y = "Frequência")

## Warning: Computation failed in `stat_bin()`.
## Caused by error in `bin_breaks_width()`:
## ! The number of histogram bins must be less than 1,000,000.
## # Did you make `binwidth` too small?
```



Identificação de outliers




que podem indicar falhas atípicas ou erros de registro.

4. Análise Bivariada


Visualização de relações entre variáveis

```
ggplot(dados, aes(x = PONTO, y = POS)) +
  geom_point(alpha = 0.5) +
  labs(title = "Dispersão entre PONTO e POS", x = "PONTO", y = "POS")
```



Análise de correlação

```
dados_num <- dados %>%
  select_if(is.numeric)
cor_matrix <- cor(dados_num, use = "complete.obs")
corrplot(cor_matrix, method = "color", type = "upper",
  tl.col = "black", tl.srt = 45,
  title = "Matriz de Correlação entre Variáveis Numéricas")
```




5. Análise Multivariada

Análise de Componentes Principais

```
dados_pca <- dados_num %>%
  na.omit() %>%
  scale()

pca_result <- prcomp(dados_pca, center = TRUE, scale. = TRUE)
fviz_pca_var(pca_result,
  col.var = "contrib",
  gradient.cols = c("#00AFBB", "#E7B800", "#FC4E07"),
  repel = TRUE) +
  labs(title = "Análise de Componentes Principais")
```



Interpretação dos componentes

A Análise de Componentes Principais revelou que os componentes VIEW_ID e POS_ID explicam a maior parte da variância dos dados. O gráfico acima mostra a contribuição das variáveis para esses componentes.

6. Conclusão e Discussão

Sumário das descobertas

- Certos pontos apresentam bem mais falhas do que os outros.
- Outliers foram identificados em **LOC_ID**.
- Há correlação significativa entre as variáveis numéricas apresentadas.

Discussão sobre limitações e possíveis melhorias

- O dataset possui muitos valores faltantes que podem afetar as análises.
- Algumas variáveis categóricas poderiam ser melhor representadas.
- Seria interessante aprofundar a análise em relação a padrões temporais de falhas.